用 Python 爬取豆瓣冷门高分电影和书籍

目录：

一、选题背景：

1.自己最初之所以选择 Python 这门选修课，一方面源于 Python 语言的简洁和库的强大，另一方面也是最主要的也是自己对于网络爬虫爬取数据的兴趣。因为近几年，大数据、数据挖掘这样的概念非常火爆，并且自己也的的确确发现数据对我们生活方方面面的影响，切身感受到数据对于未来的重要意义和影响。因此，希望在未来从事数据研究方面的工作。所以希望在本科阶段学习 Python 和爬虫。

2.自己平时对看电影和看书很有兴趣，但是对于热门精彩的高分影片和书籍早已看完，然后就很容易陷入片荒、书荒的时期，因此想要获得豆瓣上那些不算热门的精致的高分电影和书籍。

基于以上两点，自己确定了这个选题，一方面提升自己对 Python 和爬虫的应用能力，另一方面为自己提供一个电影和书籍的推荐渠道。

（项目为原创）

二、分析、开发、测试过程介绍：

网络爬虫的过程通常分为三步：获取数据、解析数据、分析数据。本次项目中，重点在于前两者。

1、分析过程：

据了解，网络上关于豆瓣电影、书籍的爬虫基本是两种，第一种是直接在某个排行榜上爬取数据，这样访问的页面少，时间快；第二种是直接 for 循环大遍历，这样获取的数据大，暴力操作也较为容易。但是前者爬取的数量太少，后者太过浪费时间，两种方式对于选题“冷门高分”而言都不是合适的策略。

因此我最终决定结合两种方式的优势来爬取数据，即先在榜单上选取合适的电影或图书，然后把它们的 URL 存下来，再通过这些 URL 去一一访问它们各自的信息页面，然后获取信息并存储。

然后本次项目一共有四个爬虫，分别是用了四个不同的榜单，四个榜单分别是“豆瓣电影 TOP250”，“豆瓣图书 TOP250”，“最新电影”和“小说类图书”。前两个榜单网页 html 的结构大致相似，也较为基础。“最新电影”榜单的网页 html 内容是动态获取的，“加载更多”也需要模拟网页动态点击。“小说类图书”的 html 结构和 TOP250 相似，但是数据量较大，爬虫爬取时极容易假死。**（对于各种爬虫，具体策略及方案的选择和实施会在开发过程中有详细介绍）**

2、开发过程：

（1）获取数据

获取数据阶段是通过 URL 向服务器请求 html。因此，开发前必然要了解豆瓣网站 URL 的请求命令格式。通过访问不同的电影、书籍界面可以发现，它们各自的 URL 前面部分基本是一样的，只是在 subject 后有一段数字代表不同的电影和书籍作品，算是一个特定的标识符。（具体如下图所示）不过通过大量访问发现，

这些标识符是随机的，没有规律，并且不同数字之间也有大量页面是空页面。因此，用 for 循环来遍历直接访问这些页面的量太大，而且效率太低，不予采用。

（图为作品页面的 URL）

A. 爬虫一和二（TOP250 榜单）：

所幸的是，我们发现豆瓣的页面提供了各式各样的榜单，其中比较著名的有 TOP250 榜单。并且 TOP250 榜单不同页的 URL 链接是有规律可寻的。由于每一页有 25 部电影,所以第一页的 start 为 0,第二页为 25,第三页为 50,以此类推……

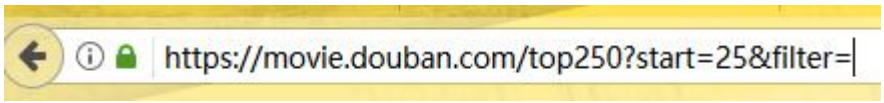

（图为 TOP 排行榜的 URL）

TOP250 榜单是豆瓣自己提供的评分在前 250 的作品，并且还提供了一些具体的信息（评分，评价人数等）和电影页面的 URL 链接。因此在这个榜单上选取合适的作品，把它们的 URL 链接爬下来，再通过这些 URL 进入电影页面爬取更多详细数据，是一个不错的爬虫策略。（由于豆瓣读书 TOP250 的界面与豆瓣电影基本类似，因此不再另截图说明）

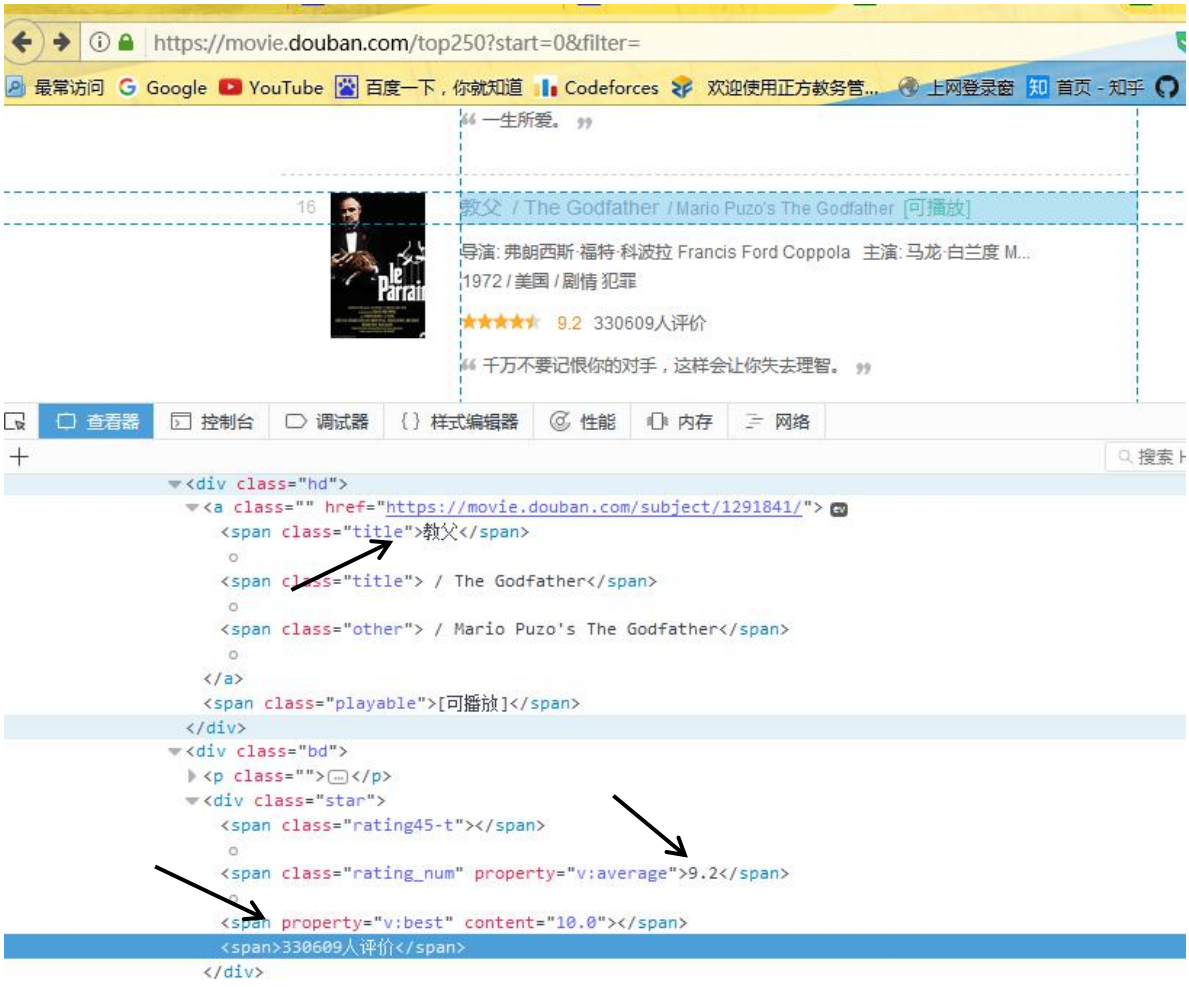

（图为 TOP250 页面的 html）

B. 爬虫三（“最新”电影榜单）：

但是这种爬虫策略固然很好，但是毕竟 TOP250 只有 250 部电影，量太少，而且都是已经在被各个地方提及多次的经典电影，并不能满足获取冷门高分电影的需求。因此决定在选电影的“最新”这一排行榜上选择合适的电影爬取，所幸这一排行榜的 URL 也是有规律可寻。

但是最终发现，虽然 URL 也是有规律可寻，但它的分页并不是页面的转换，**而是在同一页面设置了动态加载按钮“加载更多”**。这样的话用 for 循环遍历访问便是无效的，必须要模拟浏览器点击操作。于是采用第三模块 Selenium 和轻型浏览器 PhantomJS 的组合来用代码模拟浏览器点击操作。考虑到时间因素，用 for 循环连续点击了 20 次，大概是页面有了 400 部作品后开始爬取数据。

（图为选电影排行榜的页面及 URL）

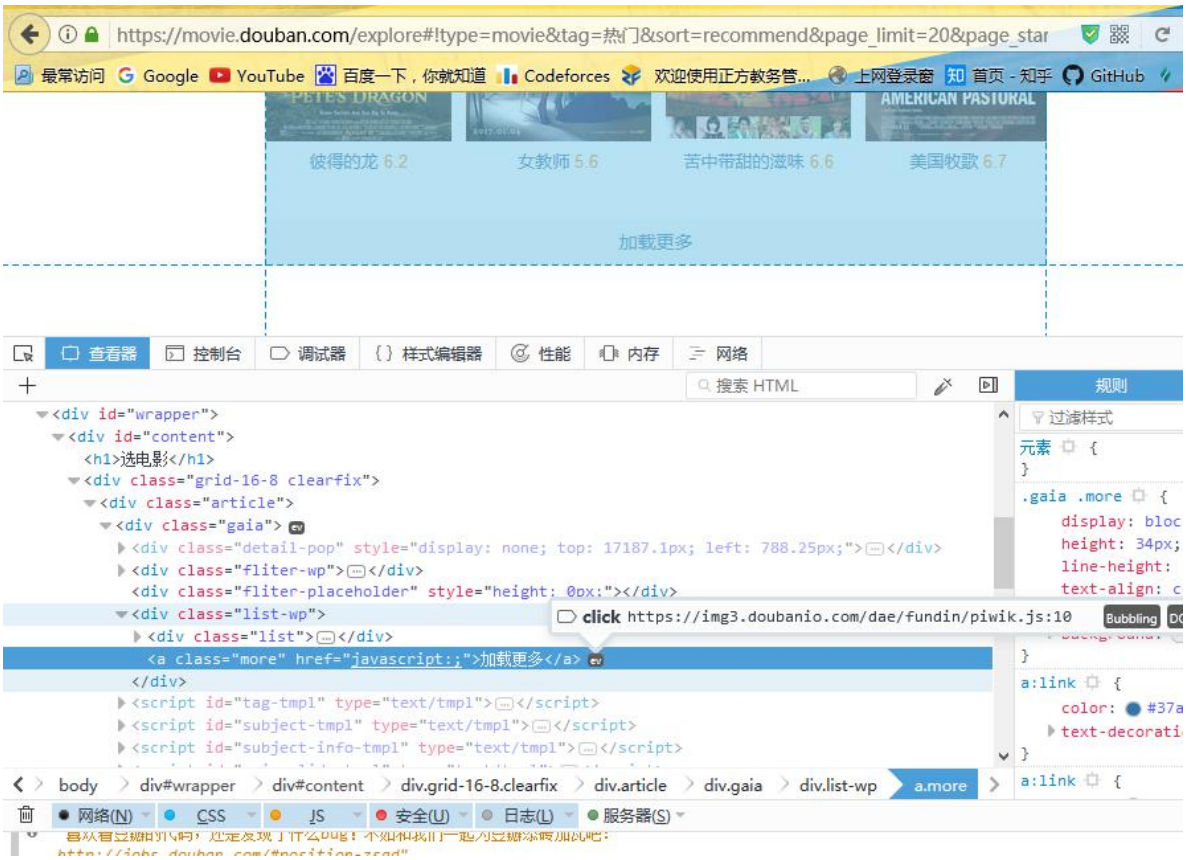

（图为选电影排行榜的页面动态按钮）

同时，也遇到了一个问题，便是这一页面的电影信息是通过 Javascript 动态获取的，因此虽然在加载后的界面通过查看器能获得信息，但是在通过 requests 获取的 html 源代码中是没有这些信息的。所以决定采用第三方模块 Selenium 来获取动态界面，以解决这一问题。

（图为选电影页面 html 中 Js 加载前后的对比）

不过这次的爬虫和 TOP250 不同，可能会访问大量界面获取大量信息（其实考虑到时间因素，并没有爬取太多数据），但是出于谨慎考虑，为了防止豆瓣封 IP，还是采取了一些简单的反“反爬”策略。由于 Selenium 的机制是模拟浏览器加

载页面，因此使用了 PhantomJS 作为模拟浏览器来加载，一定程度上可以减缓获取 html 的速度，不容易被豆瓣发现。然后又用了 time 模块中的 sleep()方法，设置每加载一个网页时间间隔为一秒，因此作为反“反爬”策略进行爬虫。

C.爬虫四（“小说”榜单）：

该网页的 html 和 TOP250 一样，也是静态的，因此最初也是按照 TOP250 的思路去获取数据，也没什么问题，但是每次获取到一半的时候卡死（如下图所示，在爬到第 12 本书时假死）。

这样陆续卡死 N 次后，不得已做出防假死的策略。即用 while 循环语句和 try……except……语句以及 time 模块中的 timeout 的结合，使爬虫如果在获取某一网页时卡死时，便不断循环地去获取这个网页，直到获取成功为止。在改进策略后才得以发现，第 16 本书《飘》一共申请了 9 次才申请成功（我这里 timeout 时限设置的是 10s，也就是说花了一分半才申请成功），真是难怪会有 N 次卡死。

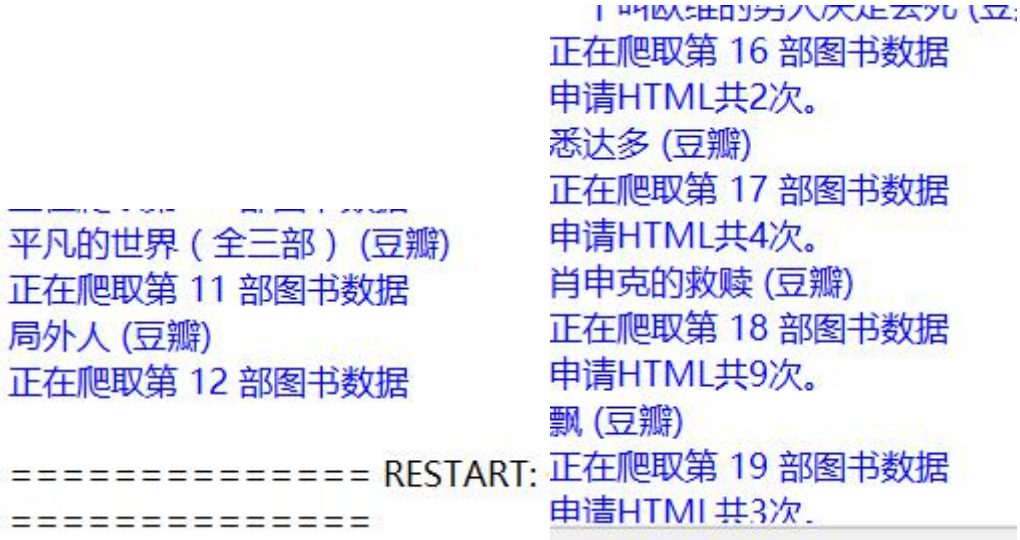

（图为第四只爬虫爬取时的界面交互图）

（2）解析数据

获取数据最终决定使用 requests 和 Selenium 这两个第三方模块作为工具来获取数据，也就是网页的 html。

接下来需要做的便是解析数据了。不过在对于解析数据工具的选择上却有波折，最终直接是用正则表达式，但是正则由于其局限性，匹配的错误率较高，容

易产生错误信息。因此，最终决定换成 Xpath 来解析数据。在网络上，有一句话形容正则和 Xpath，感觉非常形象，“如果提取信息就像找一个建筑，那么正则表达式就是告诉你，这个建筑的左边是什么、右边是什么、以及这个建筑本身有哪些特征，但这样的描述在全国范围内可能有很多地方的建筑都符合条件，找起来还是不太方便，除非你限制范围，比如指定北京海淀区等。而 XPath 就是告诉你这个建筑在中国-北京-海淀区-中关村-中关村大街-1 号，这样找起来就方便了很多”。

同样的，在解析数据之前，必然要先了解豆瓣 html 的格式及规律。所幸作品页面的 html 是静态页面，并且信息也较为全面。最终综合考虑，决定在电影方面，选取电影名称，导演，主演（前两个），剧情简介，海报，评分及评价人数等特征多维度说明一部电影；在图书方面，选取书名，作者简介，内容简介，海报，评分及评价人数等特征说明一本书。

最终，综合各方面因素，对于电影、图书两个 TOP250 榜单，选取的是评价大于八分且评价人数小于 200000 的作品并记录。对于“最新”的排行榜，选取的是前一百部评价大于七点五的作品并记录。在记录方面，除海报外的其他内容均记录在 TXT 文本文件中，海报单独记录并编号，可通过 TXT 文件中的序号信息寻得。**（代码和爬取的数据全都在附带的文件中）**

3、测试过程

在测试的过程中，值得一提的是发现豆瓣的网站是存在 BUG 的，比如这部罪恶之城，在 TOP250 榜单中给的链接打开却显示“页面不存在”。在运行测试过程中，这个地方卡了很长时间。发现后在代码中加了一个特判，即如果链接打开是页面不存在，则跳过这条链接。

三、对自己工作的评价：

整体而言，对于此次项目的自我评价还是比较满意的。项目完成的过程中自己学到了很多东西，比如 URL 的格式和原理，一系列基础的前端知识如 html 和 Js 等，xpath 的一些语法和格式，基本的反“反爬”策略的设计，以及 python 很多第三方模块如 requests，lxml，Selenium 等的运用。另外，在项目中也遇到了很多 BUG，然后每次调完 BUG 看着爬虫一点点爬数据时，特别有成就感和愉

悦感。唯一遗憾的是，由于时间关系和项目选题等原因，有很多想尝试的东西暂没有在项目中完成，比如模拟登录，多线程爬虫，更多的反“反爬”策略的设计，还有一些工具如 BeautifulSoup 和 Scrapy 框架的应用等，十分遗憾。不过所幸是此次项目也极大地激发了自己对于爬虫的兴趣。因此，项目提交后，自己仍想继续学习研究爬虫，并将成果放到 Github 上。因此，最终打分的话，认为自己可以达到 90+。

四、课程总结、对课程的批评和建议：

总体来说，python 这个两学分的选修课要求很严格，不过相比其它同学分低要求的课程而言，收获也是巨大的，并且课程的学习并没有停留在对语法、知识点的记忆上，而是理论与实践相结合，使自己的动手能力也相应提升。

课程的批评和建议的话，我个人的体会是前期过于轻松，后期过于忙碌。大概是由于实验课和理论课时间错开的缘故，最初上课期间并没有太多的实践机会。另外，按我个人的学习经验而言，语言课的学习更重要的是实践而绝非理论的记忆，因为每次实践中遇到问题，再去解决问题的过程让我对语法知识点的记忆尤为深刻。因此我希望老师能更加重视对这门课的实践教育，比如课程的平时布置一些实践的小任务，或是在 Github 上放一个小项目让大家一起维护或学习。然后对于语法知识的教学也没必要面面俱到，因为基本语法基本大家看看书就可以知道，然后在课堂上的时间更多的讲一些写 Python 程序的小技巧或是一些小项目的开发过程，我觉得这样会让我们的收益更多。